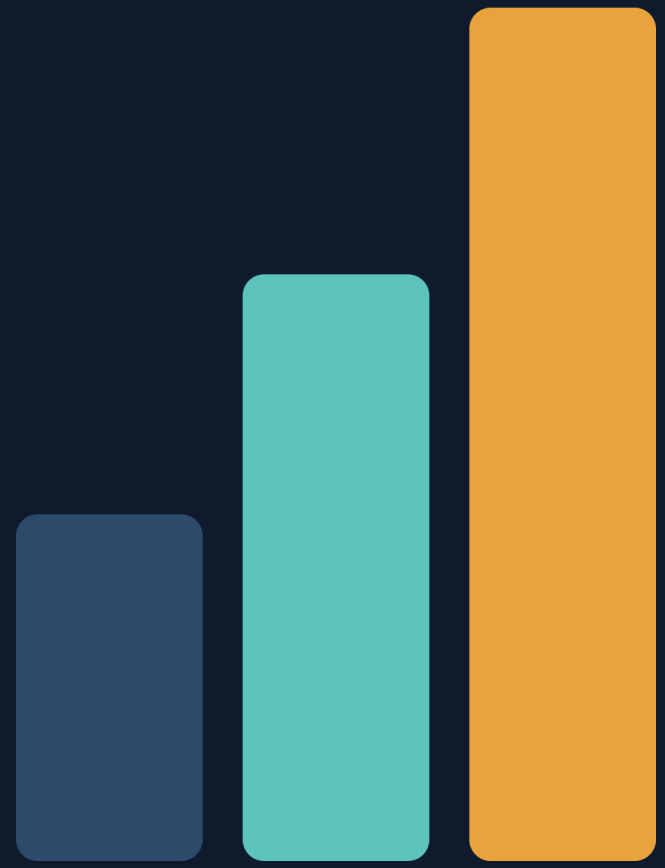
ПРОЕКТ 3 · МОДУЛЬ 1

Уровень дохода

Кому банку предложить премиальную кредитную карту



adult.csv · 32 561 человек · перепись США

ЗАКАЗЧИК

Кому предложить премиальную карту

Ложное предложение

Низкий доход, а карту предложили

Отказ и расходы на рассылку.

Пропущенный клиент

Высокий доход, а карту не предложили

Упущенная выгода.

Данные: 32 561 человек, доход больше 50K у 24%. Цена ошибок сопоставима, поэтому важны и precision, и recall.

ДАННЫЕ

Что нашли в данных

5,7%

пропусков «?» в workclass и occupation, в native.country — 1,8%

24

полных дубликата: убрали до разбиения на train и test

2

признака убрали: fnlwgt (вес записи) и education (копия education.num)

99999

в capital.gain: все 124 человека зарабатывают больше 50K, признак «подсказывает» ответ

БЕЗ УТЕЧЕК

Что и когда «учится»

1	**Разбиение**	Делим данные до любой обработки, дубликаты убираем заранее
2	**Pipeline**	Импутер, скейлер и энкодер обучаются только внутри фолда
3	**StratifiedKFold(5)**	Модель и порог выбираем по кросс-валидации на train
4	**Тест**	Открываем один раз, в самом конце

61,7%

состоятельных клиентов нашла логистическая регрессия

Accuracy 0,856 выглядит хорошо, но «всем <=50K» даёт 0,759: редкий класс прячется за средним.

БЛОК Б · ВЫБОР МОДЕЛИ

Две модели, пять фолдов

Метрика	Логрегрессия	Случайный лес
F1	0,640	0,664
ROC-AUC	0,897	0,916
PR-AUC	0,732	0,800

Среднее по 5 фолдам на train. F1 считаем по классу >50K.

ВЫБРАЛИ

Случайный лес

Лучше по F1, ROC-AUC и PR-AUC

БЛОК Б · МЕТРИКА И ПОРОГ

Метрика F1, порог 0,38

0,729

F1 на отложенном тесте

76%

состоятельных клиентов найдено (recall)

70%

верных предложений (precision)

Accuracy скрывает перекос классов (76 / 24), поэтому берём F1 по классу >50K. Порог подобран на предсказаниях кросс-валидации по train, а не на тесте.

Для сравнения, порог 0,50 даёт F1 0,694 и recall 61%.

БЛОК В · ДИСБАЛАНС КЛАССОВ

Пять методов внутри CV



ЛОВУШКА

Ресемплинг до кросс-валидации завышает F1 до 0,92 вместо честных 0,665: копии записей попадают в валидацию.

БЛОК В · АНАЛИЗ ОШИБОК

Где модель ошибается чаще

Женщины

31%

высокодоходных женщин пропущено, у мужчин — 22%

До 25 лет

52%

высокодоходных молодых пропущено: модель их почти не видит

В браке

30%

состоящих в браке с доходом до 50K получили ложное предложение

На тесте в целом: пропущено 24% состоятельных, ложных предложений 10,5%.

БЛОК В · ДОПУСТИМОСТЬ ПРИЗНАКОВ

Признаки, которые нужно убрать

Защищённые признаки и их прокси. Ориентир — ECOA (США); для своей страны проверить с юристом.

sex | race | native.country | marital.status | relationship

ЦЕНА ОТКАЗА · ROC-AUC

0,916 → 0,869

Остаются прокси

occupation, hours.per.week, education.num: ошибки по группам нужно мониторить

ВЫВОД

Отдавать можно как пилот, не как автоматическое решение

1

Проверить на данных банка

Обучали на переписи США 1994 года, а цель — доход, не платёжеспособность

2

Пересчитать порог

По реальной цене ложного предложения и пропущенного клиента

3

Убрать защищённые признаки

И следить за ошибками по группам после каждого обновления